Projet intégrateur d'IA générative multi modale
Livrable 2 — Ingestion, index et recherche

RenDacDiag

MaintiDoc appliqué au diagnostic des véhicules Renault et Dacia

Élément	Valeur
Équipe	RenDacDiag : Qossai Elaidi, Ebba Soufiane
Encadrant	À compléter
Semaine	2 sur 6
Dépôt Git	Lien à compléter · src/, eval/, tests/, docker-compose.yml

Résultats de la semaine

Indicateur	Valeur
Éléments indexés (corpus en mode développement)	211 : 140 sections, 50 tableaux, 21 figures
Recall@5, code exact + BM25 (40 questions)	92 %
MRR@10, code exact + BM25	0.88
Tests d'accès sans fuite	10 / 10
Tests automatisés	20 / 20 réussis
Recherche dense (BGE-M3) et image (CLIP)	Mesurées : MRR@10 0.92, Top-1 82 % (section 5)

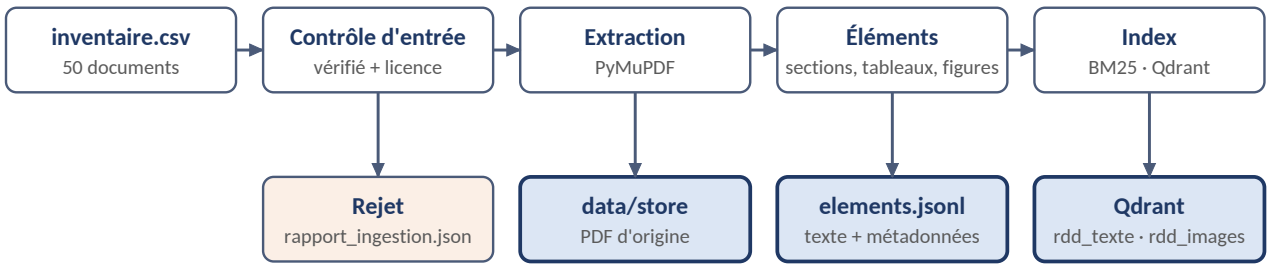
1. Objectif de la semaine

Le livrable 2 rend le corpus interrogeable : ingestion des documents vérifiés, découpage en éléments citables, index lexical et vectoriel, recherche hybride filtrée par les droits et par la famille de moteur, et première mesure de qualité. Le modèle vision-langage et la rédaction des réponses arrivent au livrable 3.

Attendu (cahier des charges)	Réalisé	Fichier
Ingestion des documents, OCR, découpage	Extraction PyMuPDF par section, tableau et figure ; OCR prévu pour les scans (aucun dans le corpus)	ingestion/
Métadonnées par élément	Document, version, page, élément, famille, codes, voyants, groupes, empreinte	ingestion/pipeline.py
Recherche textuelle et visuelle	BM25 + BGE-M3 + CLIP (texte vers image et image vers image)	index/, search/
Recherche par code exact	Codes OBD et UDS à 6 chiffres décodés (ex. DTC038096 → P0380)	dtc.py
Fusion des résultats	Reciprocal Rank Fusion pondérée	search/retriever.py
Contrôle d'accès	Jeton, filtre de recherche, ouverture des pages et images	api/main.py, access.py
Mesures	Recall@5, MRR@10, nDCG@5 sur 40 questions + 10 tests d'accès	eval/

2. Ingestion

L'ingestion lit l'inventaire, écarte tout document non vérifié ou sans licence, puis découpe chaque PDF en éléments qu'une réponse pourra citer avec leur page.



Chaque élément porte : document, version, page, identifiant (ex. DOC-SCH-03_fig1), famille de moteur, codes, voyants, groupes d'accès, empreinte SHA-256.

Figure 1 — Chaîne d'ingestion.

- **Règle du corpus appliquée par le code :** en mode normal, seuls les documents au statut « vérifié » sont indexés. À la date de ce rapport, les 50 documents sont encore « à vérifier » : le mode normal n'indexe donc rien et le rapport d'ingestion liste les 50 refus. Les mesures ci-dessous utilisent le mode développement (--inclure-non-verifies).
- **Découpage par élément :** une section par titre, un élément par tableau (cellules lues dans leur cadre pour garder les espaces), une figure par schéma ou pictogramme. Les libellés dessinés dans les schémas (ex. « Compresseur du turbo », « P0299 ») sont ajoutés au texte de la figure, ce qui rend les schémas trouvables par la recherche textuelle.
- **Contexte :** le titre et le sous-titre du document sont ajoutés en tête de chaque élément, pour qu'un élément court (ex. « Causes probables ») reste rattaché à son code.

- **Liens :** la rubrique « Documents liés » n'est pas indexée comme texte ; elle devient une métadonnée (documents_lies).

Type d'élément	Nombre	Exemple d'identifiant
Section	140	DOC-DTC-P0301_s02 (causes probables)
Tableau	50	DOC-PROC-01_tab1 (codes, outillage)
Figure	21	DOC-SCH-03_fig1, DOC-VOY-V04_fig1

3. Index et recherche hybride

Quatre listes de candidats sont calculées puis fusionnées. Chacune ne contient que des éléments que l'utilisateur a le droit de lire, et, si la famille de moteur est connue, que des éléments de cette famille ou communs.

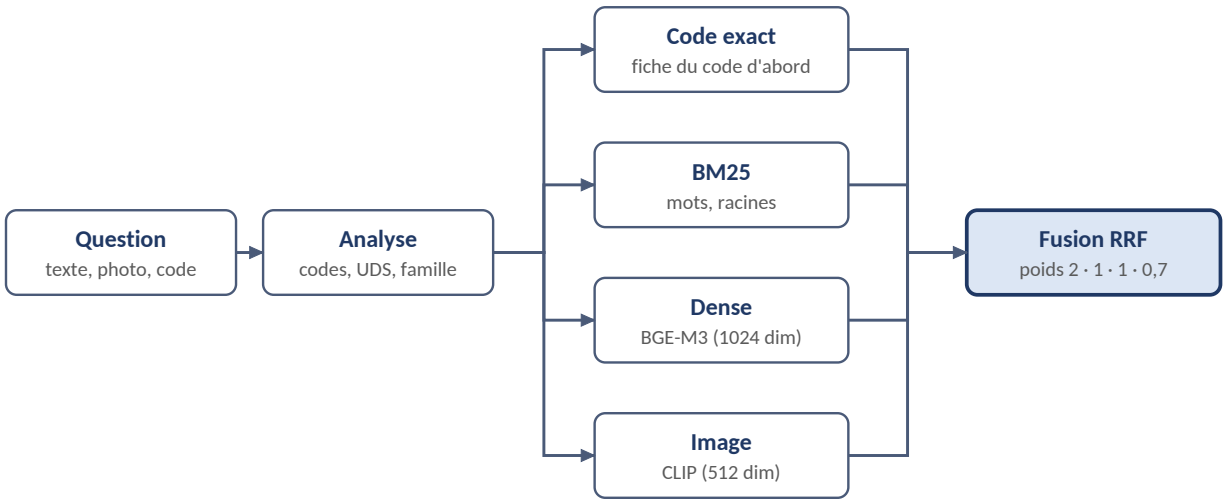


Figure 2 — Recherche hybride et fusion.

Liste	Principe	Rôle
Code exact	Codes extraits de la question, y compris au format UDS ; la fiche du code passe en premier	Précision sur les questions avec code
BM25	Mots normalisés (accents, pluriels, racine de 7 lettres), mots vides retirés	Termes techniques exacts
Dense	BGE-M3 multilingue dans Qdrant, filtre sur groupes et famille	Questions formulées avec d'autres mots
Image	CLIP : texte vers image, ou photo vers image	Voyants et schémas

La fusion RRF additionne, pour chaque élément, poids / (60 + rang) sur chaque liste. Le code exact pèse double : une question qui cite P0302 doit d'abord renvoyer la fiche P0302. La famille de moteur est déduite de la question (« dCi », « diesel », « TCe »…) ou imposée par l'interface. Les codes constructeur comme P1453 sont signalés à part : ils ne figurent pas dans le corpus.

Choix techniques

- Qdrant en mode local (fichiers sur disque) sur le poste de l'équipe, ou en serveur avec docker-compose : même code.
- BGE-M3 et CLIP tournent sur CPU : le livrable 2 ne dépend pas du GPU distant, réservé au VLM.
- Un embedder « hash » sans modèle sert aux tests et à l'intégration continue ; ses scores ne mesurent rien et ne sont pas rapportés.

4. Contrôle d'accès

Trois des quatre points de contrôle prévus au livrable 1 sont en place ; le quatrième (serveur MCP) arrive au livrable 4.

Point de contrôle	Mise en œuvre	Test
API	Jeton JWT signé (8 h), mot de passe haché PBKDF2, quota de 30 requêtes par minute, question limitée à 500 caractères	401, 413, 429

Point de contrôle	Mise en œuvre	Test
Recherche	Filtre des groupes appliqué à chaque liste avant fusion	10 sondes : aucune fuite
Ouverture d'une source	Page rendue en PNG ou image de figure servie seulement si l'utilisateur peut lire le document	403 pour le réceptionnaire sur une procédure
Journal	Utilisateur, point d'accès, décision, documents renvoyés ; la question n'est pas stockée, seulement son empreinte	Test sur le contenu du journal

Le groupe « invites » a été ajouté dans l'inventaire aux fiches voyants et aux règles générales, pour appliquer la matrice d'accès du livrable 1 (l'invité de démonstration ne lit que ces documents).

5. Évaluation

Le jeu de 40 questions (eval/questions_l2.csv) couvre six catégories ; chaque question indique les documents attendus et le rôle de l'utilisateur. Les mesures sont calculées au niveau du document.

Configuration	Recall@5	MRR@10	nDCG@5	Top-1
BM25 seul	87 %	0.86	0.82	72 %
Code exact + BM25	92 %	0.88	0.87	75 %
+ dense (BGE-M3)	92 %	0.92	0.90	82 %
Hybride complet (+ CLIP)	92 %	0.92	0.90	82 %

Catégorie	BM25 seul	Code exact + BM25
Code défaut (13)	85 %	100 %
Symptôme (7)	67 %	67 %
Procédure (5)	100 %	100 %
Schéma (7)	100 %	100 %
Voyant (6)	86 %	86 %
Général (2)	100 %	100 %

La recherche par code exact règle toutes les questions qui citent un code (85 % → 100 %), y compris le code UDS DTC038096. Les échecs restants sont des questions de symptômes formulées avec d'autres mots que les documents : « perte de puissance en côte, sifflement » ne partage aucun mot avec la fiche P0299 (« suralimentation insuffisante »), et « voyant orange » renvoie des fiches voyants plutôt que les règles générales. C'est le cas que la recherche dense devait couvrir. Mesurée depuis (tableau ci-dessus), elle améliore le classement (MRR@10 0.88 → 0.92, Top-1 75 % → 82 %) mais ne règle pas ces deux cas : le rappel reste à 92 %.

Limites de la mesure

- 40 questions écrites par l'équipe : le score est optimiste tant qu'elles ne sont pas complétées par de vraies questions de techniciens.
- Corpus en mode développement (documents pas encore vérifiés).
- Une seule normalisation lexicale a été testée ; elle n'a pas été ajustée question par question.

6. Tests et intégration continue

20 tests pytest passent sans modèle ni réseau (embedder « hash ») ; GitHub Actions les lance à chaque envoi.

Fichier	Ce qui est vérifié
test_dtc.py	Extraction des codes, décodage UDS (codes réels lus sur une valise Autel), codes génériques et constructeur
test_ingestion.py	Rejet des documents non vérifiés, métadonnées complètes, images des figures présentes
test_search.py	Fiche du code en tête, code UDS retrouvé, aucune fuite pour réceptionnaire et invité, filtre diesel, code constructeur signalé
test_api.py	Mot de passe faux refusé, jeton obligatoire, ouverture autorisée et refusée, budget de longueur, journal sans question en clair

7. Points ouverts et semaine 3

- **Vérification du corpus :** bloquante pour l'indexation en mode normal ; à terminer au plus tôt.
- **Qualité du corpus :** certaines fiches DTC citent comme « codes voisins » des codes réservés (ex. P0384 « Reserved by SAE J2012 ») ; à corriger lors de la vérification.
- **Mesure dense et image :** faite (section 5). La liste CLIP n'est utilisée que pour une question visuelle (schéma, voyant…) ou une photo : appliquée à toutes les questions, elle faisait tomber le Top-1 à 68 %.
- **Semaine 3 :** intégration du VLM (lecture des voyants, des plaques et des écrans de valise), citations vérifiées et sorties structurées.